

alpha,beta-CROWN을 이용한 신경망 검증

윤나리

1. 탐색 : alpha,beta-CROWN 모델 및 설정 파일

α,β -CROWN 저장소는 다양한 사전 학습 신경망 모델과 검증 설정 파일을 제공한다. 모델 디렉터리에는 MNIST 및 CIFAR-10 데이터셋을 대상으로 한 완전연결신경망(MLP), 합성곱신경망(CNN), ResNet, 적대적 학습(adversarial training) 모델, 비-ReLU 활성화함수를 사용하는 모델 등이 포함되어 있다. 모델은 주로 PyTorch 형식으로 제공되며, ONNX 형식 모델 역시 설정 파일을 통해 사용할 수 있다.

검증 설정은 YAML 파일로 관리된다. YAML 파일에는 모델 정보, 데이터셋, 검증 속성, 공격 설정, 솔버 파라미터 및 Branch-and-Bound(BaB) 전략 등이 정의되어 있다. 이러한 설정 기반 방식은 사용자가 각 검증 문제를 직접 코드로 작성해야 하는 Marabou와 차별화된다. 또한 α,β -CROWN은 MNIST 및 CIFAR-10 데이터 로더와 PGD 공격기를 내장하고 있으며, PyTorch와 ONNX 형식을 모두 지원한다.

Marabou는 주로 ONNX 모델을 대상으로 SMT 및 LP 기반 검증을 수행하는 반면, α,β -CROWN은 경계 전파(bound propagation)와 Branch-and-Bound를 결합하여 보다 빠르고 확장성 있는 검증을 제공한다.

2. 모델, 데이터셋, 검증 속성

본 실험에서는 과제 3(Marabou)와의 직접적인 비교를 위해 동일한 구조의 MNIST 분류용 다층 퍼셉트론(MLP)을 사용하였다. 네트워크 구조는 입력층(784), 은닉층(64, 32), 출력층(10)으로 구성되며 ReLU 활성화함수를 사용하였다. 모델은 Adam 옵티마이저(learning rate = 0.001)를 이용하여 5 epoch 동안 학습되었으며, 테스트 정확도 96.31%를 달성하였다.

α,β -CROWN의 입력 형식에 맞추기 위해 모델에 Flatten 레이어를 추가한 후 ONNX(opset 14) 형식으로 변환하였다. 검증은 MNIST 테스트 데이터셋의 처음 100개 샘플을 대상으로 수행하였다.

검증 속성은 입력 이미지에 대해 $\epsilon = 0.01$ 의 ℓ_∞ (L-infinity) perturbation이 가해졌을 때 모델의 예측 결과가 변하지 않는 강건성(robustness) 검증으로 설정하였다.

3. 검증 결과 및 해석

검증은 kFSB 분기 전략, β -CROWN 최적화 반복 횟수 20회, 샘플당 제한 시간 60초 조건에서 수행하였다. 실험은 GPU 없이 CPU 환경에서 진행되었다.

결과	%	평균 시간(초)
safe-incomplete (CROWN 경계만으로 검증)	97	0.281
safe (BaB 완전 증명)	1	0.567
unsafe-pgd (적대적 예제 발견)	2	0.008
timeout	0	-
합계	100	0.282

전체 100개 샘플 중 97개는 CROWN 선형 완화만으로 강건성이 검증되었다. 1개 샘플은 Branch-and-Bound를 통해 완전한 안전성 증명이 이루어졌다. 반면 2개 샘플에서는 PGD 공격을 통해 적대적 예제가 발견되어 검증 속성이 만족되지 않음이 확인되었다.

특히 한 샘플에서는 $\epsilon = 0.01$ 의 매우 작은 perturbation만으로도 분류 결과가 변경되었으며, 이는 해당 입력이 결정 경계(decision boundary) 근처에 위치함을 의미한다. 전체적으로 98%의 샘플이 안전하다고 판정되어, 학습된 MLP가 작은 입력 변화에 대해 비교적 안정적인 특성을 가지고 있음을 확인할 수 있었다.

4. alpha,beta-CROWN vs Marabou 비교

과제 3에서 사용한 Marabou와 동일한 네트워크 구조 및 검증 조건을 기준으로 비교를 수행하였다.

항목	alpha, beta-CROWN	Marabou(과제3)
----	-------------------	--------------

검증됨 (safe)	98/ 100 (98%)	72/ 100 (72%)
반례 발견 (unsafe)	2/ 100 (2%)	28/ 100 (28%)
타임아웃	0	0
샘플당 평균 시간(초)	0.282	8.3
속도	~29배	1배
확장성	CNN, ResNet, VNN-COMP	소형 FC/CNN만 가능
모델 형식	ONNX 또는 PyTorch(.pth)	ONNX 전용
검증 속성 지정	YAML(norm, epsilon, vnnlib)	Python API (샘플별)
검증 방법	경계 전파 + BaB	LP/ SMT (ReLU분할)

실험 결과 α, β -CROWN은 Marabou보다 약 29배 빠른 검증 속도를 보였다. 이는 대부분의 샘플을 CROWN 경계 전파만으로 처리할 수 있기 때문이다. 반면 Marabou는 ReLU 활성화함수에 대한 제약 조건을 반복적으로 해결해야 하므로 검증 시간이 상대적으로 길다.

또한 α, β -CROWN은 CNN, ResNet과 같은 대규모 모델 검증을 지원하며 VNN-COMP 대회에서도 우수한 성능을 보였다. 반면 Marabou는 상대적으로 작은 규모의 신경망 검증에 적합하다. 사용 편의성 측면에서도 α, β -CROWN은 하나의 YAML 파일만으로 전체 실험을 관리할 수 있어 보다 효율적이었다.

5. α, β -CROWN의 장단점

장점

* 빠른 검증 속도

CROWN 기반 경계 전파를 통해 대부분의 샘플을 단일 패스로 검증할 수 있어 매우 빠른 성능을 제공한다.

* 높은 확장성

CNN, ResNet 등 대규모 신경망에 대해서도 검증이 가능하며, VNN-COMP 벤치마크에서 우수한 성능을 입증하였다.

* 통합된 적대적 공격 기능

PGD 공격기를 내장하고 있어 반례를 빠르게 탐색할 수 있다.

* 유연한 설정 시스템

모델, 데이터셋, 검증 속성, 솔버 파라미터 등을 YAML 파일 하나로 관리할 수 있다.

단점

* Safe-Incomplete 결과 존재

CROWN 완화만으로 얻어진 결과는 건전하지만 완전한 수학적 증명은 아니다.

* GPU 의존성

대규모 모델 검증 시 GPU 사용이 사실상 필수적이다.

* 설치 및 환경 구성의 복잡성

다양한 의존성 패키지가 필요하며 환경 설정 과정이 다소 복잡하였다.

6. 결론

본 실험에서는 α, β -CROWN을 이용하여 MNIST 기반 MLP 모델의 강건성을 검증하였다. $\epsilon = 0.01$ 의 ℓ_∞ perturbation에 대해 98%의 샘플이 안전하다고 판정되었으며, 평균 검증 시간은 0.282초로 매우 우수한 성능을 보였다. 또한 동일한 조건의 Marabou와 비교했을 때 약 29배 빠른 속도를 나타냈으며, 더 높은 확장성과 편의성을 제공하였다. 이러한 결과는 α, β -CROWN이 대규모 신경망 검증을 위한 효율적이고 실용적인 도구임을 보여준다.